Nota de Aula sobre Processo estocástico e Simulação de Monte Carlo

Prof. Antonio Francisco

Este capítulo explora conceitos avançados que são de grande aplicação na área de Finanças. A ideia aqui é discutir a formação de cenários possíveis para variáveis econômicas. Esses cenários são gerados a partir de processos estocásticos vinculados às variáveis. A Simulação de Monte Carlo é o procedimento de geração de possíveis cenários para as variáveis relevantes usando processos estocásticos e a composição desses cenários em um modelo. A Simulação de Monte Carlo pode ser usada para análise de riscos, geração de cenários para o fluxo de caixa de um projeto, ou mesmo para a projeção da DRE, do fluxo de caixa de uma empresa e para a valoração de derivativos.

Antes de iniciarmos a discussão formal, considere o preço de um ativo em um data *t* como X_t. Note que existe um conjunto de valores de preços *X* possíveis para a data específica *t*. Assim, para cada instante de tempo *t*, existe uma distribuição de probabilidades para os possíveis valores de *X* naquele instante. X_t então é a variável aleatória que representa o conjunto dos preços do ativo em *t*.

Formalmente, um processo estocástico representado por *X* é uma coleção de variáveis randômicas definida em um espaço de probabilidades. Usaremos neste texto a ideia de que essa coleção de variáveis randômicas é feita em um intervalo de tempo. Um conjunto de valores ao longo do tempo para a variável randômica forma uma série temporal. Assim, em uma série temporal de preços do barril de petróleo, por exemplo, para cada instante de tempo *t*, *t+1*, *t+2*, ...*t+n*, temos valores de X_t, X_{t+1}, X_{t+2}, ... X_{t+n} para a variável randômica preço do barril de petróleo. Lembre-se que o valor que X_t pode assumir em *t* tem uma distribuição de probabilidades associada, ou seja, X_t é uma variável randômica, X_{t+1} é outra e assim sucessivamente, o que faz de *X* uma coleção de variáveis randômicas. Logo, *X* é processo estocástico, já que representa uma coleção de variáveis aleatórias para cada instante de tempo *t*.

Dessa forma, um processo estocástico é caracterizado por uma lei de probabilidades e ele é dito estacionário se as propriedades estatísticas da variável, ou seja, se os momentos da distribuição de probabilidades (média, desvio padrão, curtose e assimetria) são constantes ao longo do tempo. O processo estocástico pode ser contínuo no tempo se para cada instante com intervalo infinitesimal no tempo temos uma variável aleatória associada, se

isso não ocorre, o processo é dito discreto no tempo. O processo pode ser contínuo na variável randômica se o valor que essa variável pode assumir está em um intervalo contínuo, caso contrário, o processo é dito discreto na variável randômica.

O passeio aleatório (*random walk*)

Imagine que você pode lançar uma moeda infinitas vezes e que você atribui o valor $\epsilon_t = +1$ se o resultado for cara e $\epsilon_t = -1$ se for coroa para cada lançamento no instante t. A variável ϵ_t é aleatória e possui uma distribuição de probabilidades associada. Suponha que para cada lançamento a probabilidade de dar cara é p e a de dar coroa é $1-p$. Se a moeda não é viciada, cada resultado (cara ou coroa) tem probabilidade $p=0.5$ de ocorrer. Considere que cada lançamento é independente dos demais.

Vamos considerar ainda que uma variável aleatória em $t=0$ tem seu valor $X_0=0$. Se considerarmos que X_t é a soma dos valores associados a cada resultado do lançamento da moeda do instante $t=0$ até um instante t qualquer, temos um passeio aleatório, chamado de *random walk* (se $p=0,5$, temos um passeio aleatório simétrico).

Suponha por exemplo que a moeda foi lançada 6 vezes e os resultados dos lançamentos foram {1, -1, 1, 1, 1, -1}. Assuma que $X_0=0$. Essa sequência de lançamentos tem $X_6=2$, ou seja, a soma 1+(-1)+1+1+1+(-1). Assim, o passeio aleatório apresentado será definido como:

$$X_{t+1} = X_t + \epsilon_{t+1}$$

Podemos generalizar a equação do passeio aleatório permitindo que ϵ_t possa assumir qualquer valor no conjunto dos números reais ($\mathcal{R}$), sendo uma variável aleatória com média zero e desvio padrão igual a σ_ϵ.

Evidentemente, podemos observar algumas propriedades do passeio aleatório simétrico ($p=0,5$). Suponha que tenhamos t observações e, assim, X_t seja conhecido. A esperança matemática de X_{t+1} é dada por: $E[X_{t+1}]=X_t$, já que por ser simétrico, a esperança matemática de ϵ_{t+1} é igual a zero. Em outras palavras, a melhor estimativa para X_{t+1} é o valor conhecido X_t. Um processo estocástico que apresenta essa característica é chamado de *martingale*.

Considere que os resultados das observações de X são independentes, ou seja, não existe uma relação de dependência entre X_t e um valor anterior qualquer X_{t-k}. Para cada instante de tempo, temos uma variável aleatória com uma distribuição de probabilidades associada a essa variável e independente do passado. Se considerarmos ainda que a distribuição de probabilidades é a mesma não importando o instante de tempo, dizemos que o processo é identicamente distribuído. Um processo estocástico com essas duas características é dito identicamente e independentemente distribuído.

Para cada instante discreto de tempo t, a sequência X_t acima é formada pela soma de variáveis aleatórias até aquele instante. Assumindo que n representa o número de observações até um instante de tempo no futuro, sendo que o tempo é dividido em intervalos Δt, a variância de $X_{t+n\Delta t}$ é dada por:

$$\sigma^2_{X_{t+n\Delta t}} = n\sigma^2_{\epsilon}$$

O movimento Browniano ou processo de Wiener

Um processo estocástico bastante discutido na literatura é o movimento Browniano. Vamos considerar as variações de um processo estocástico como função de uma variável aleatória contínua, com distribuição normal, média igual a zero e variância igual a um, ou seja, podemos representar essa variável aleatória por $\epsilon_t \sim N(0,1)$. Além disso, os incrementos do processo são independentes e identicamente distribuídos. Vamos imaginar também um novo processo estocástico ΔZ_t formado da seguinte maneira:

$$\Delta Z = \epsilon_t \sqrt{\Delta t}$$

Se tomarmos o limite infinitesimal à direta no tempo, isto é, intervalos de tempo Δt muito pequenos, nós teremos incrementos infinitesimais (que representamos por dt) e o processo Z_t passa a ser um processo estocástico contínuo chamado de processo de Wiener ou movimento Browniano:

$$dZ = \epsilon_t \sqrt{dt}$$

Um processo estocástico é chamado de processo ou cadeia de Markov se a distribuição de probabilidades no instante t depende apenas da informação disponível naquele

momento, não importando o passado do processo. O processo de Wiener definido acima é um processo de Markov.

Note que como $\epsilon_t \sim N(0,1)$, o valor de $E[\Delta Z]=0$ e a variância de ΔZ é igual a Δt. Vale lembrar também a noção de derivada de uma função. A derivada da função da variável aleatória em relação ao tempo, $X=f(t)$, representa quanto o valor da função $f(t)$ varia com uma mudança infinitesimal em t. A derivada de $f(t)$ é representada por $f'(t)$ ou dX/dt. Imagine, por exemplo, que X é o preço de um determinado ativo. Então dX/dt é a derivada de X em relação ao tempo, ou seja, a razão entre a variação de X e uma mudança infinitesimal no tempo. O comportamento de uma variável qualquer X pode ser representado pelo modelo do movimento Browniano da seguinte forma:

$$dX = \sigma dZ$$

onde, σ é o desvio padrão dos desvios da variável X.

Note que se conhecemos σ e X_0 e se sabemos que $\epsilon_t \sim N(0,1)$, podemos então simular diferentes cenários para X. Isso é feito a partir da geração de valores de ϵ_t com um procedimento de geração aleatória (ou pseudoaleatória). A partir desses valores, é possível construir um processo estocástico qualquer X usando a equação a seguir.

$$dX = \sigma\epsilon_t\sqrt{dt}$$

O movimento Browniano com tendência

O modelo do movimento Browniano pode ser ampliado incorporando uma tendência ao mesmo:

$$dX = \alpha dt + \sigma dZ$$

Nesse caso, α é o parâmetro de tendência e σ é o desvio padrão. O valor esperado das mudanças na variável aleatória ΔX é dado por $E[\Delta X]=\alpha\Delta t$. A variância da variável aleatória é dada por $\sigma^2\Delta t$.

Note que no movimento Browniano com tendência (ou não) a variável aleatória X tem uma distribuição normal, logo ela pode ter valores negativos.

O movimento Browniano geométrico

Já foi discutido que algumas séries de preços (*S*) apresentam distribuição lognormal, ou seja, $X=ln(S)$ tem uma distribuição normal. Apenas para relembrar, um preço não pode ter valor negativo e, assim, a distribuição lognormal é frequentemente utilizada para representar a distribuição de probabilidade dos preços. O logaritmo do preço é que apresenta distribuição normal.

Relembramos acima o conceito de derivada de uma função em relação ao tempo. Conforme vimos, a derivada mede a relação da variação infinitesimal da função em relação a uma variação infinitesimal do tempo.

Vamos investigar então como se comportam as variações infinitesimais para as variáveis *S* (distribuição lognormal) e *X* (distribuição normal), sabendo que $X=ln(S)$, onde *X* é um processo estocástico que segue um movimento Browniano com tendência e *S* é o valor de um ativo financeiro que tem uma distribuição lognormal. Isso nos leva a um importante processo estocástico representativo de séries financeiras que é o movimento Browniano geométrico apresentado como:

$$dS = \mu S dt + \sigma S dz$$

Como vimos, se *S* tem uma distribuição lognormal e, por definição, a variável $X=ln(S)$ tem uma distribuição normal. Além disso, X_t-X_{t-1} é o retorno relativo em tempo contínuo de *S*, ou seja a rentabilidade de *S* com capitalização contínua. Note que o retorno em tempo contínuo pode ser escrito como $ln(S_t/S_{t-1})$ e tem uma distribuição normal com variância $\sigma^2 dt$.

Em cálculo estocástico, as relações entre as derivadas de *X* e *S* não são de visualização direta. Pode ser demonstrado que se *S* segue o processo estocástico acima definido como movimento Browniano geométrico, a variável *X* segue o movimento Browniano com tendência dado por:

$$dX = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dZ$$

A demonstração dessa relação foge do escopo deste texto. A partir de um valor inicial S_0, o valor esperado de S em um instante qualquer t, $E[S_t]$, e a variância são definidos por:

$$E[S_t] = S_0 e^{\mu t}$$

$$\sigma_{S_t}^2 = S_0^2 e^{2\mu t}\left(e^{\sigma^2 t} - 1\right)$$

Processos com reversão à média

Preços de commodities e taxas de câmbio tendem a exibir um comportamento com reversão a um valor médio. Um exemplo de processo com reversão à média é o processo de Ornstein-Uhlenbeck, apresentado na seguinte equação:

$$dX = \eta(\bar{X} - X)dt + \sigma dz$$

Nesse caso, η é a velocidade de reversão à média. As variações de X dependem do nível em que X se encontra e por isso não podemos afirmar que os incrementos são independentes, embora o processo ainda seja um processo de Markov. Para um dado instante t, partindo de x_0, temos as seguintes equações:

$$E[X_t] = \bar{X} + (X_0 - \bar{X})e^{-\eta t}$$

$$\sigma_{[x_t - \bar{x}]}^2 = \frac{\sigma^2}{2\eta}(1 - e^{-2\eta t})$$

Decomposição de Cholesky

Como vimos acima, os modelos de processos estocásticos discutidos anteriormente podem ser utilizados para a geração de cenários que podem ser aplicados em um modelo para a realização da simulação de Monte Carlo. É importante observar que nosso modelo pode ter mais de um processo estocástico. Além disso, os processos podem estar correlacionados ou não. Na verdade, é muito comum em Finanças estarmos interessados em dois processos estocásticos S_1 e S_2 para variáveis que são correlacionadas. Ambos os processos têm distribuição lognormal.

Para a geração de dois processos correlacionados, precisamos gerar aleatoriamente duas séries de ϵ_t (uma para cada variável em estudo), de tal forma que os processos estocásticos obtidos estejam correlacionados. A decomposição de Cholesky é utilizada para resolver esse problema. Considere que os processos estocásticos S_i podem ser representados por:

$$dS_{i,t} = S_{i,t-1}\mu_i dt + S_{i,t-1}\sigma_i \epsilon_{i,t}\sqrt{dt}$$

O subscrito $i=1...N$ identifica o processo estocástico. Precisamos gerar N processos estocásticos para as N variáveis aleatórias que são correlacionadas. A correlação deve ser incorporada ao processo gerador $\epsilon_{i,t}$. É importante lembrar que ϵ_i tem uma distribuição normal com média igual a zero e variância igual a 1. A decomposição de Cholesky tem como objetivo gerar processos estocásticos que estejam coerentes com a matriz de correlação esperada (M_ϵ) entre as variáveis $S_{i=1,2,...}$. A matriz de correlação M_ϵ é simétrica e, assim, pode ser decomposta em uma matriz triangular inferior (uma matriz com zeros acima da diagonal principal), com os fatores de Cholesky. O procedimento é exemplificado abaixo com dois ativos financeiros que têm correlação igual a ρ:

$$M_\epsilon = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} = QQ'$$

A decomposição de Cholesky pode ser feita da seguinte forma:

$$\begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} = \begin{bmatrix} a_{11} & 0 \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} a_{11} & a_{21} \\ 0 & a_{22} \end{bmatrix} = \begin{bmatrix} a_{11}^2 & a_{11}a_{21} \\ a_{21}a_{11} & a_{21}^2 + a_{22}^2 \end{bmatrix}$$

Assim: $a_{11}^2 = 1$, $a_{21} = \rho$ e $a_{22} = (1-\rho^2)^{1/2}$.

Agora, considere um vetor de variáveis aleatórias independentes φ, com distribuição normal, média igual a zero e variância igual a 1. A partir desse vetor φ gerado de forma independente, podemos encontrar o vetor ϵ, que considera a correlação entre as variáveis, a partir dos resultados da decomposição de Cholesky:

$$\begin{bmatrix} \epsilon_1 \\ \epsilon_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \rho & (1-\rho^2)^{1/2} \end{bmatrix} \begin{bmatrix} \varphi_1 \\ \varphi_2 \end{bmatrix}$$

Da equação acima, temos que $\epsilon_1 = \varphi_1$. Logo ϵ_1 tem distribuição normal, média igual a zero e variância igual a 1, ou seja, $\epsilon_1 \sim N(0,1)$. Ainda da equação acima, temos que a variável aleatória $\epsilon_2 = \rho\ \varphi_1 + (1-\rho^2)^{1/2}\varphi_2$. Note que essa variável é a soma de duas variáveis

independentes multiplicadas por duas constantes. Uma variável aleatória formada por uma combinação linear de duas outras variáveis aleatórias independentes tem sua variância igual à soma das variâncias multiplicadas pelos respectivos quadrados das constantes da combinação linear. Então:

$$var(\epsilon_2) = \rho^2 var(\varphi_1) + (1 - \rho^2) var(\varphi_2) = 1$$

Por definição, as variâncias de φ_1 e φ_2 são iguais a 1 e assim, o desenvolvimento da equação acima faz com que a variância de ϵ_2 também seja igual a 1. O que dizer então sobre a correlação entre ϵ_1 e ϵ_2? Lembre que nosso objetivo com a decomposição de Cholesky é gerar duas séries com correlação igual a ρ.

A correlação entre ϵ_1 e ϵ_2 é dada por:

$$Corr(\epsilon_1, \epsilon_2) = E[\epsilon_1 \times \epsilon_2] = E\left[\varphi_1 \times (\rho\varphi_1 + (1 - \rho^2)^{1/2}\varphi_2)\right]$$

$$Corr(\epsilon_1, \epsilon_2) = \rho E[\varphi_1^2] + (1 - \rho^2)^{1/2} E[\varphi_1 \varphi_2)]$$

$E[\varphi_1 \varphi_2)] = 0$, já que as variáveis são independentes e, por definição, $E[\varphi_1^2] = 1$. Logo:

$$Corr(\epsilon_1, \epsilon_2) = \rho$$

conforme o procedimento de decomposição de Cholesky pretende gerar.

Simulação de Monte Carlo

Como já dissemos, a simulação de Monte Carlo permite a geração de cenários estocásticos para variáveis. Essa geração de cenários pode ser usada para avaliar riscos em projetos, precificar de derivativos, gerar cenários de taxas de juros, avaliar riscos, dentre outras aplicações. Para a utilização das equações dos processos estocásticos anteriormente discutidos, necessitamos gerar números aleatórios com normal. Vários programas de computador apresentam funções para a geração de números aleatórios com distribuição normal.

Uma das alternativas para operacionalizar a simulação de Monte Carlo é a geração de números aleatórios de acordo com uma distribuição uniforme. Na distribuição uniforme, todos os números têm a mesma chance de ocorrência. O número aleatório gerado pela distribuição uniforme pode ser usado na geração de um número aleatório com uma

distribuição normal, a partir da inversão dessa função. Pacotes como o Excel, da Microsoft, têm funções apropriadas para a geração de números com uma distribuição uniforme (a função "aleatório" do Excel) e funções para a inversão da função distribuição de probabilidades.

O número gerado com a distribuição de probabilidades normal é então utilizado na equação do modelo do processo estocástico avaliado. Além disso, como vimos, se o objetivo for gerar cenários para duas variáveis correlacionadas, a decomposição de Cholesky é utilizada na simulação de Monte Carlo.

Exemplos

1- Considere que o preço da uma commodity (S_1) segue um movimento browniano geométrico. A taxa de crescimento anual do preço da commodity é de 2% e a volatilidade anual é igual a 30%. Assuma que o ano tem 252 dias úteis e que queremos simular o comportamento da variável em base diária. Se o preço inicial da commodity for de 50, e os dois primeiros valores de uma variável aleatória gerada de acordo com uma distribuição normal forem 0.215 e 1.212, qual o valor da commodity no segundo dia?

Solução:

A equação do movimento browniano geométrico pode ser escrita como:

$$S_{1,t} = S_{1,t-1} \times exp\left[\left(\mu_1 - \frac{\sigma_1^2}{2}\right)\Delta t + \sigma_1 \epsilon_{1,t}\sqrt{\Delta t}\right]$$

Assim, temos:

$$S_{1,1} = 50 \times exp\left[\left(0{,}02 - \frac{0{,}3^2}{2}\right)\left(\frac{1}{252}\right) + 0{,}3 \times 0{,}215 \times \sqrt{\frac{1}{252}}\right] = 50{,}199$$

$$S_{1,2} = 50{,}199 \times exp\left[\left(0{,}02 - \frac{0{,}3^2}{2}\right)\left(\frac{1}{252}\right) + 0{,}3 \times 1{,}212 \times \sqrt{\frac{1}{252}}\right] = 51{,}357$$

2- Considere agora que os retornos de uma commodity S_2 estão correlacionados com os retornos da commodity S_1 do exercício anterior e que o coeficiente de correlação é 0,7. A taxa de crescimento anual de S_2 é de 3%, a volatilidade anual é igual a 20% e o preço

inicial é de 30. Usando a decomposição de Cholesky apresente o valor de S_2, dois períodos à frente, sendo que os dois primeiros valores de uma variável aleatória gerada de acordo com uma distribuição normal foram -0.312 e 0,954.

Solução:

Aplicando a decomposição de Cholesky:

$$\begin{bmatrix}\epsilon_{1,1}\\ \epsilon_{2,1}\end{bmatrix} = \begin{bmatrix}1 & 0\\ 0{,}7 & (1-0{,}7^2)^{1/2}\end{bmatrix}\begin{bmatrix}0{,}215\\ -0{,}312\end{bmatrix}$$

$$\begin{bmatrix}\epsilon_{1,2}\\ \epsilon_{2,2}\end{bmatrix} = \begin{bmatrix}1 & 0\\ 0{,}7 & (1-0{,}7^2)^{1/2}\end{bmatrix}\begin{bmatrix}1{,}212\\ 0{,}954\end{bmatrix}$$

Os valores para as variáveis aleatórias a serem utilizados para gerar os cenários da simulação de Monte Carlo para os preços de S_2, corrigidos pela decomposição de Cholesky, são $\epsilon_{2,1}$=*-0,0723* e $\epsilon_{2,2}$=*1,530*.

Dessa forma, temos para S_2:

$$S_{2,1} = 30 \times exp\left[\left(0{,}03 - \frac{0{,}2^2}{2}\right)\left(\frac{1}{252}\right) + 0{,}2 \times (-0{,}0723) \times \sqrt{\frac{1}{252}}\right] = 29{,}974$$

$$S_{2,1} = 29{,}974 \times exp\left[\left(0{,}03 - \frac{0{,}2^2}{2}\right)\left(\frac{1}{252}\right) + 0{,}2 \times 1{,}530 \times \sqrt{\frac{1}{252}}\right] = 30{,}559$$